Применение графов для классификации финансовых транзакций

Выполнил:
студент группы М80-404 Сорокин Д.М.
Руководитель:
доцент каф. 804 Соболь В.Р.

Постановка задачи

Проанализировать финансовые транзакции с целью предотвращения мошеннических операций. Разбивается на две подзадачи:

- Реализовать классификатор, способный отличить мошеннические транзакции от не мошеннических

- Построить графы на основе финансовых переводов. На графах посчитать новые признаки (расстояние до ближайшего мошенника, количество мошенников в круге радиуса *n*), добавить их в модель и проверить значимость

Источник данных

- Взяты с онлайн-сообщества специалистов по анализу данных и машинному обучению *kaggle.com*
- Созданы синтетически симулятором *PaySim*
- Выборка моделируется на основе реальных транзакций сервиса мобильных переводов компании, работающей в 14 африканских странах
- При создании симулируется злонамеренное поведение
- Временное окно – 1 месяц. Количество транзакций - 6362620 , 8213 из которых мошеннические

Данные

	step	type	amount	nameOrig	oldbalanceOrg	newbalanceOrig	nameDest	oldbalanceDest	newbalanceDest	isFraud
0	1	PAYMENT	9839.64	C1231006815	170136.00	160296.36	M1979787155	0.0	0.0	0
1	1	TRANSFER	181.00	C1305486145	181.00	0.00	C553264065	0.0	0.0	1
2	1	CASH_OUT	181.00	C840083671	181.00	0.00	C38997010	21182.0	0.0	1
3	1	PAYMENT	9478.39	C1671590089	116494.00	107015.61	M58488213	0.0	0.0	0
4	1	PAYMENT	3454.08	C686349795	9031.96	5577.88	M1831010686	0.0	0.0	0

- **step** аналог времени. 1 step = 1 час (всего 744 = 30 дней)
- **type** тип транзакции (CASH-IN, CASH-OUT, DEBIT, PAYMENT, TRANSFER)
- **amount** сумма перевода
- **nameOrig** ID пользователя-отправителя
- **oldbalanceOrg** баланс отправителя до транзакции
- **newbalanceOrig** баланс отправителя после транзакции
- **nameDest** ID пользователя-получателя
- **oldbalanceDest** баланс получателя до транзакции. ID, начинающийся с буквы **M** - Merchant (магазин). В этом случае информация отсутствует
- **newbalanceDest** баланс получателя после транзакции
- **isFraud** пометка о мошеннической транзакции

Предварительный анализ

Название	Значение
Всего транзакций	6362620
Мошеннических	8213
Ср. сумма перевода мошеннической транзакции	1467967.29
Ср. сумма перевода не мошеннической транзакции	178197.04
Уникальных клиентов	4777844
Количество магазинов	2151495
Уникальных магазинов	2150401
Мошеннических транзакций с магазинами	0
Клиенты, взаимодействующие друг с другом более 1 раза	0

Название	Значение
CASH-IN (frauds)	1399284 (0)
CASH-OUT	2237500 (4116)
DEBIT	41432 (0)
PAYMENT *(=кол-во магазинов)*	2151495 (0)
TRANSFER	532909 (4097)
Максимальная цепочка транзакций	11
Максимальное количество приема одним клиентов	118
Максимальное количество отправлений одним клиентов	31

Типичная ситуация для мошеннических транзакций

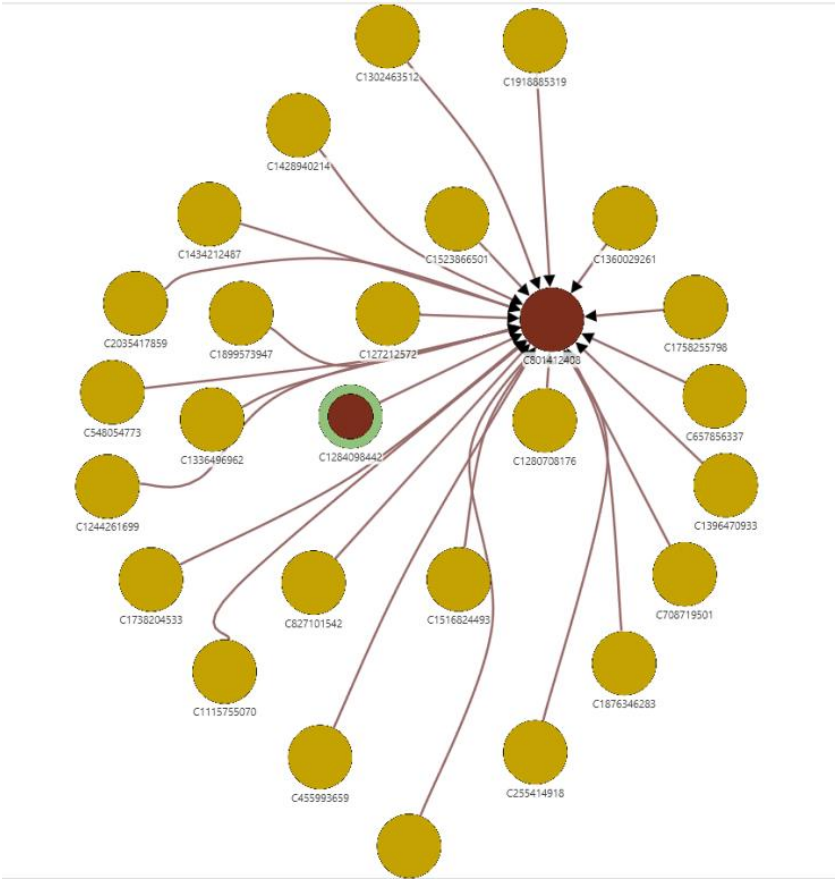

Используемые методы классификации

- Случайный лес (Random forest)
- Метод k-ближайших соседей (K-neighbors)
- Наивный байесовский классификатор

Результаты на «сырых» данных

$$precision = 0.994$$
$$recall = 0.822$$
$$F_1 = 0.900$$

$$precision = 0.954$$
$$recall = 0.794$$
$$F_1 = 0.867$$

$$precision = 0.595$$
$$recall = 0.204$$
$$F_1 = 0.304$$

Проектирование признаков

	step	type	amount	oldbalanceOrg	isFraud	hour	newSender	newReceiver	merchant	fraudsEarly	LTS	LTR	IZoB
0	1	4	181.00	181.0	1	1	1	1	0	0	0	0	1
1	1	1	181.00	181.0	1	1	1	1	0	0	0	0	1
2	1	3	7107.77	183195.0	0	1	1	1	1	0	0	0	0
3	1	3	671.64	15123.0	0	1	1	1	1	0	0	0	0
4	1	3	1373.43	13854.0	0	1	1	1	1	0	0	0	0

Выборка сокращена до **461382** транзакций. Мошеннические сохранены в исходном объеме.

Убранные признаки: step, ID клиентов, новый баланс отправителя, старый и новый баланс получателя
Добавленные признаки:

- **hour** шаг был конвертирован в 24 часов формат
- **newSender** первое ли появление отправителя
- **newReciver** первое ли появление получателя
- **merchant** является ли получатель магазином
- **fraudEarly** были ли раньше клиенты текущей транзакции замечены в мошеннических
- **LTS** время с момента предыдущей транзакции в качестве отправителя
- **LTR** время с момента предыдущей транзакции в качестве получателя
- **IZoB** остается ли 0 на балансе у отправителя

Отбор признаков

	step	type	amount	oldbalanceOrg	isFraud	hour	newSender	newReceiver	merchant	fraudsEarly	LTS	LTR	lZoB
0	1	4	181.00	181.0	1	1	1	1	0	0	0	0	1
1	1	1	181.00	181.0	1	1	1	1	0	0	0	0	1
2	1	3	7107.77	183195.0	0	1	1	1	1	0	0	0	0
3	1	3	671.64	15123.0	0	1	1	1	1	0	0	0	0
4	1	3	1373.43	13854.0	0	1	1	1	1	0	0	0	0

0.08*	0.06	0.24	0.38		0.11	1.25e-5	0.012	0.007	0.0004	2e-7	0.015	0.063

Значимость признаков

RFE (recursive feature elimination) – рекурсивное отсечение признаков

Результат после отбора признаков

$$precision = 0.987$$
$$recall = 0.912$$
$$F_1 = 0.948$$

$$precision = 0.955$$
$$recall = 0.958$$
$$F_1 = 0.957$$

$$precision = 0.547$$
$$recall = 0.189$$
$$F_1 = 0.281$$

Нормализация данных

$$x_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}$$

	type	amount	hour	iZoB
0	4.0	181.00	181.0	1.0
1	1.0	181.00	181.0	1.0
2	3.0	7107.77	183195.0	1.0
3	3.0	671.64	15123.0	1.0
4	3.0	1373.43	13854.0	1.0

	type	amount	hour	iZoB
0	0.015625	0.707010	0.707010	0.003906
1	0.003907	0.707091	0.707091	0.003907
2	0.000016	0.038770	0.999248	0.000005
3	0.000198	0.044368	0.999015	0.000066
4	0.000215	0.098652	0.995122	0.000072

Результаты после нормализации

$$precision = 0.999$$
$$recall = 0.994$$
$$F_1 = 0.997$$

$$precision = 0.997$$
$$recall = 0.974$$
$$F_1 = 0.986$$

$$precision = 0.195$$
$$recall = 0.005$$
$$F_1 = 0.011$$

Визуализация с помощью графов

Результаты

- Произведен анализ финансовых транзакций с целью предотвращения мошеннических операций
- Реализована прикладная программа, визуализирующая графы переводов
- Спроектирована модель, способная классифицировать финансовые транзакции
- Произведены процедуры по улучшению качества предсказаний, принесшие результат

Спасибо за внимание!